# 第 2 章 大语言模型（LLM）的崛起

人工智能的发展并非简单的性能线性提升过程，而更像是能力组织方式的阶段性跃迁。回顾过去数十年的技术轨迹可以发现，每一次看似“精度提升”的突破背后，实际上都隐藏着表示结构与学习范式的转变。深度学习时代的早期突破主要集中在感知层面：图像识别、语音识别、机器翻译等任务成为技术竞赛的核心，模型通过明确的目标函数逼近输入与输出之间的映射关系。这一阶段的成功极大推动了产业应用，使机器在视觉与语音等感知任务上达到甚至超过人类水平。然而，从结构上看，这一时期的人工智能仍然是“任务驱动型”的。每一个问题对应一个模型，输入与输出边界清晰，训练目标明确，评估指标单一。模型能力局限于特定场景，其知识表示高度专用化。当任务发生变化时，往往需要重新设计模型结构或重新训练系统。人工智能因此呈现出高度割裂的形态，其进步更多体现为局部函数逼近能力的增强，而非整体认知结构的重组。

大语言模型的出现改变的并非某一个基准指标，而是这种能力组织结构本身。通过在海量文本语料上进行统一预训练，模型不再围绕单一任务优化，而是构建一个共享的高维语义空间；通过“预测下一个词”这一极度简洁却具有普适性的目标函数，模型在参数空间中压缩并编码了跨领域知识结构；通过规模扩展与对齐机制的引入，模型逐渐从单纯的语言概率预测器转变为能够参与复杂交互与推理的系统。规模定律揭示了模型性能与参数规模、数据规模之间近似幂律关系，但更关键的是，当规模跨越某一复杂度阈值后，能力形态开始发生跃迁。模型不再只是记忆与模仿，而开始呈现推理、规划与跨任务迁移等行为特征。这种变化意味着人工智能从“任务工具集合”走向“统一生成系统”。语言成为通用接口，模型能够参与信息组织、逻辑构建与内容生成。生成式人工智能因此被视为一次范式转变，而不仅仅是算力堆叠的结果。其革命性并不在于参数数量本身，而在于能力组织方式发生了重构。

## 2.1 从 NLP 到生成式 AI：ChatGPT 带来的范式革命

从宏观层面看，生成式人工智能的出现并非孤立事件，而是自然语言处理长期演化逻辑的阶段性结果。ChatGPT 所引发的范式转变，看似突然，实则建立在数十年技术积累之上。语言始终是人工智能领域最具挑战性的对象之一，因为它既是符号系统，也是意义载体；既具有形式结构，也嵌入社会与文化语境之中。理解生成式 AI 的革命性意义，必须回到一个更基础的问题：在不同历史阶段，人类是如何尝试将“语言”这一高度复杂的认知现象转化为可计算对象的？每一次技术路径的变化，背后都隐含着对语言本质的不同理解。从规则系统到概率模型，从局部统计到分布式表示，语言的形式化方式不断改变，也逐渐为大规模生成模型的出现铺平道路。因此，在讨论 ChatGPT 所代表的生成式范式之前，有必要回溯自然语言处理的历史轨迹，考察语言如何一步步被转译为机器可处理的结构。

### 2.1.1 语言如何被形式化：从规则到概率的转向

自然语言处理的发展历史，本质上是一部关于“语言如何被形式化”的历史。早期 NLP 以符号规则系统为核心，其理论基础深受形式语言学与逻辑学传统影响。研究者试图通过语法规则、句法树与词典结构刻画语言结构，希望将人类语言转化为可执行的符号体系。在这一范式下，语言被视为一个可解析的形式系统，其结构可以被精确定义，其语义可以通过逻辑表达式映射。语言理解因此被等同为规则推理：只要规则完备，机器便能够在符号空间中完成与人类相似的推演过程。语言被拆解为词法、句法与语义模块，解析器负责句法树构建，语义模块负责逻辑表示转换，推理模块负责规则匹配与演绎。这一结构反映了当时人工智能研究的主流思想，即通过符号表示与逻辑推理实现机器智能。在这一时期，大量研究围绕语法解析、知识表示与规则系统展开，希望通过逐步扩展规则库，使机器逐渐具备语言理解能力。然而，这种结构很快遭遇现实挑战。语言并非封闭系统，其表达具有高度歧义性与创造性，语义理解往往依赖上下文与共享背景知识。随着表达复杂度提升，规则数量呈指数级增长，系统维护成本急剧上升。语言中的隐喻、反讽、多义词与跨句依赖关系，使得规则体系难以穷尽。规则驱动范式因此逐渐暴露出可扩展性不足的问题，也使研究者开始重新思考语言形式化的可能路径。

规则系统的困难不仅体现在工程复杂度上，更源于语言本身的开放性特征。与数学或程序语言不同，自然语言的表达空间几乎是无限的，新的词语组合、语义延伸与语境变化不断出现，这意味着任何有限规则系统都难以覆盖全部情况。此外，语言理解往往依赖大量隐含知识，例如常识、文化背景以及说话者意图，这些信息很难通过显式规则完整表达。即便在相对结构化的语法分析任务中，句法歧义问题也广泛存在。例如同一句话在不同语境下可能具有不同句法结构，而纯规则系统往往难以选择最合理的解析结果。随着系统规模扩大，规则之间的冲突与冗余也逐渐增加，使得维护与扩展变得愈发困难。这些问题逐渐显现出符号主义语言处理方法的根本局限：当语言复杂度不断增加时，仅依赖人工构建规则难以维持系统可扩展性。由此，研究者开始探索另一条路径，即不再试图完全形式化语言规则，而是通过数据分析来捕捉语言使用中的统计规律。

统计学习方法的兴起，标志着语言形式化路径的第一次重大转向。语言不再被视为需要完全逻辑化的对象，而被理解为可统计建模的符号序列。在这一框架下，语言理解被转化为概率估计问题：给定上下文条件，预测某个词语或结构出现的概率。n-gram 模型通过统计词语共现频率来刻画语言生成概率，使得语言模型可以通过大规模文本语料进行训练。随后，隐马尔可夫模型（Hidden Markov Model）与条件随机场（Conditional Random Field）等概率图模型被引入自然语言处理，在分词、词性标注与命名实体识别等序列标注任务中取得重要进展。在这一阶段，语言从“规则对象”转变为“概率分布”，机器不再需要穷举所有语法规则，而是通过统计规律捕捉常见表达模式。这一转向意味着对语言不确定性的承认：语言理解不再被视为确定性逻辑推演，而是对条件概率的估计与最优选择。统计学习方法在工程上具有明显优势，因为模型可以随着数据规模增加而不断改进，而不需要人工持续扩展规则库。随着互联网文本资源的快速增长，大规模语料逐渐成为语言模型训练的重要基础，也推动了统计自然语言处理在机器翻译、信息检索与文本分类等任务中的广泛应用。

然而，统计方法虽然解决了规则系统的扩展问题，却并未真正解决语言表示能力的限制。传统统计模型通常依赖人工设计特征，例如词频统计、词形变化特征或局部上下文窗口等，这些特征往往只能捕捉浅层统计关系，而难以表达复杂语义结构。例如 n-gram 模型只能利用有限长度的上下文信息，无法有效建模长距离依赖关系；概率图模型虽然能够描述序列结构，但在处理高维特征空间时往往需要大量人工设计。与此同时，这些模型通常将语言视为线性序列，而忽略了语言中更复杂的结构关系，例如句法层级、语义角色以及跨句语境依赖。因此，尽管统计学习方法在任务性能上显著优于纯规则系统，但其对语言深层语义结构的建模能力仍然有限。从更宏观的角度看，这一阶段的自然语言处理仍然主要依赖“特征工程”：研究者需要手工设计能够反映语言规律的特征，然后利用统计模型进行训练。这种方法在数据规模较小时具有一定优势，但随着语言任务复杂度提升，人工特征设计逐渐成为新的瓶颈。

正是在这一背景下，研究者开始进一步探索能够自动学习语言表示的方法。随着计算能力提升以及神经网络模型的发展，机器学习逐渐从“特征工程”阶段过渡到“表示学习”（representation learning）阶段。与传统统计方法不同，神经网络模型能够直接从原始文本数据中学习多层次表示，使词语、句子乃至语篇结构能够被映射到连续向量空间中。这种向量化表示不仅能够捕捉词语之间的语义相似性，还能够在更高层级表达句法与语义关系。由此，自然语言处理开始进入神经网络时代，并逐渐发展出词向量模型、循环神经网络以及基于注意力机制的 Transformer 架构。这一转变意味着语言形式化方式再次发生变化：语言不再仅仅被视为符号序列或概率分布，而被表示为高维向量空间中的结构化表示。统计学习阶段所积累的大规模语料与概率建模思想，为这一转变奠定了重要基础，也为后续深度学习与大模型的发展打开了新的研究方向。

### 2.1.2 分布式表示与预训练范式的形成

深度学习的引入，使语言建模进入真正意义上的分布式表示时代。在传统符号方法中，词汇通常被视为离散符号，其意义通过词典条目或规则系统加以定义，不同词语之间缺乏可计算的连续关系。这种表示方式使机器难以捕捉语义相似性与上下文关联，因为在符号空间中，“医生”“护士”“医院”等概念彼此之间并不存在可度量的距离。早期神经网络语言模型通过词向量（word embedding）将离散符号映射到连续向量空间，使语言单位不再是孤立的符号，而成为高维空间中的点。词汇之间的语义相似性通过向量之间的距离或夹角体现，抽象语义关系则可以通过向量方向表达。例如，在向量空间中，“国王—男人 + 女人 ≈ 女王”这样的关系开始可以被几何结构刻画。语言由此从符号系统转化为连续空间中的结构化分布。语义不再依赖显式规则进行定义，而是

在大规模语料统计规律中通过训练过程隐式形成。分布式表示的核心思想在于：意义并非由单一符号承载，而是由大量维度共同编码，每个维度捕捉语言结构中的某种潜在统计模式。这一思想改变了语言建模的基本假设，也使模型能够通过梯度优化逐步学习复杂的语义结构。

在分布式表示的基础上，神经网络结构不断演化，以提升对语言序列结构的建模能力。早期神经语言模型仍然依赖固定长度的上下文窗口，模型只能观察有限数量的前文词汇，这在一定程度上限制了其对长距离依赖关系的捕捉能力。为了解决这一问题，循环神经网络（Recurrent Neural Network, RNN）被引入语言建模任务。循环结构允许模型在时间维度上传递隐藏状态，使当前时刻的表示能够包含此前序列的信息，从而使语言被视为动态展开的序列过程。随后提出的长短期记忆网络（Long Short-Term Memory, LSTM）以及门控循环单元（Gated Recurrent Unit, GRU）通过引入门控机制，在一定程度上缓解了梯度消失问题，使模型能够学习更长范围的依赖关系。这一阶段的语言模型不再局限于局部共现统计，而能够在更长的上下文范围内整合语义信息。机器翻译、语音识别与文本生成等任务的性能在此阶段得到显著提升。然而，循环结构本质上依赖顺序计算，每一步计算都必须依赖前一步隐藏状态，这种链式计算方式不仅限制了并行能力，也使梯度在长序列中传播困难。随着模型规模与数据规模的持续增长，这种结构性瓶颈逐渐显现，成为限制语言模型进一步扩展的重要因素。

这一瓶颈随着 Transformer 架构的提出而被根本性打破。Transformer 的核心创新在于引入自注意力机制（self-attention），使模型能够在一次前向计算中直接访问整个输入序列的上下文信息。与循环网络不同，自注意力机制不再依赖逐步传播的隐藏状态，而是通过查询、键和值之间的相似度计算，为每个位置动态分配注意力权重，从而构建跨位置的信息交互结构。这样，任意两个词之间的关系都可以在单层结构中直接建立，而不必通过多步传播路径间接传递。语言序列由此被建模为一个密集的关系网络，其中每个词语都能够根据上下文动态调整其表示。与此同时，自注意力结构天然适合并行矩阵计算，大幅提升了训练效率，使得模型能够在大规模数据与高性能计算资源支持下进行训练。多头注意力机制进一步允许模型在不同子空间中同时学习多种语义关系，使语言表示具备更丰富的表达能力。通过多层堆叠结构，Transformer 可以逐步整合从局部语义到全局语境的多层信息，使语言整体被嵌入到统一的高维连续空间中。这种结构不仅在表达能力与计算效率之间取得关键平衡，也为后续大规模语言模型的出现提供了可扩展的技术基础。

在结构突破的基础上，预训练思想逐渐系统化，并形成新的模型构建范式。研究者逐步意识到，与其为每一个具体任务分别设计和训练模型，不如先在海量无标注语料上进行自监督学习，让模型在语言自身的统计结构中学习普遍存在的语法规律、语义模式以及隐含的知识结构。通过掩码预测（masked language modeling）或自回归预测（autoregressive modeling）等训练目标，模型可以在不依赖人工标注的情况下获得密集学习信号。掩码预测通过随机遮盖输入序列中的部分词语，使模型在上下文信息基础上恢复缺失内容，从而学习语境依赖关系；自回归预测则通过逐词预测下一个词语，使模型在生成过程中逐步形成对语言结构的理解。随着训练语料规模持续扩大，模型开始在统一语义空间中整合来自不同领域的大量文本信息。预训练完成后，模型可以通过微调（fine-tuning）或提示（prompting）的方式适配具体任务，实现跨任务迁移能力。这种“预训练—适配”的范式改变了语言模型的能力结构：模型不再是某一任务的专用工具，而成为能够支持多种任务的通用表示平台。与此同时，研究者逐渐观察到模型规模与性能之间存在稳定关系。参数量增加可以提升表示精细度，数据规模扩大可以增强知识覆盖范围，而算力与分布式训练技术的发展则为模型规模扩展提供了现实条件。随着训练规模不断扩大，语言模型的能力呈现出明显的规模化规律，性能随模型规模增长而持续提升。

尽管如此，在这一阶段语言模型仍主要作为下游系统的基础组件存在。虽然底层表示空间已经实现共享，但具体应用仍然保持任务分割式结构。例如，文本分类模型、机器翻译模型以及问答系统通常需要在预训练模型之上构建专门的输出层，并针对特定任务进行额外训练。在这种模式下，预训练模型更像是一种高性能的特征提取与表示引擎，为不同任务提供统一的语义向量表示，而真正的任务决策仍由独立模块完成。模型能力虽然在底层实现了统一，但应用层仍然呈现出明显的模块化分工。因此，这一阶段的语言模型尚未完全成为统一的生成与推理主体。尽管如此，分布式表示与预训练范式的形成，已经完成了语言建模从符号规则系统到连续空间学习体系的重要转变。语言知识被压缩进高维向量空间中，通过大规模训练逐步形成结构化语义表示。这一范式不仅显著提升了语言理解任务的性能，也为后续生成式统一模型的出现奠定了理论与工程基础。随着模型规模与训练数据持续增长，语言模型逐渐具备更强的知识整合能力与跨任务迁移能力，语言智能的发展路径也开始从传统任务模型体系走向更统一、更具扩展性的生成式模型框架。

### 2.1.3 ChatGPT 与交互范式的重构

真正的范式转变并非单纯源于参数规模的扩张，而是来自交互方式的根本改变。当 ChatGPT 以对话系统形态进入公众视野时，语言模型第一次以可持续对话的主体身份出现，而不再只是隐藏在产品背后的算法组件。此前无论是 BERT 还是早期 GPT 系列，更多作为下游系统的能力引擎存在，例如搜索排序、机器翻译或文本分类等任务中的核心算法模块，用户并不直接面对模型本身。模型通常被封装在复杂的软件系统内部，通过 API 调用或服务接口向外提供特定功能。在这种结构中，模型只是软件体系的一部分，其能力被拆分并嵌入到不同任务模块之中。然而，在 ChatGPT 所代表的对话式界面中，模型本身成为交互中心，自然语言既是输入方式，也是输出形式，人与模型之间的沟通不再依赖中间接口或任务分发模块。用户面对的并非某个具体功能，而是一个可以通过语言表达进行交互的通用系统。模型不再被封装为单一任务 API，而是在统一生成框架下处理摘要、改写、翻译、分析、推理乃至代码生成等多种需求，表现出明显的跨任务整合能力。

这种变化首先体现在任务定义方式的改变。在传统软件系统中，任务通常由开发者预先定义，用户通过按钮、菜单或表单等结构化界面触发相应功能。例如翻译系统只负责语言转换，搜索系统负责信息检索，文本编辑器负责文档处理，每种能力都对应一个明确的软件模块。然而在大模型系统中，任务不再由系统固定划分，而是通过用户语言描述动态生成。用户无需理解模型内部结构，也无需选择具体算法模块，只需表达意图与约束条件，模型便在高维语义空间中自动完成路径展开。Prompt 因此不再只是普通输入文本，而成为一种声明式控制语言：它规定目标、设定角色、限定风格与边界，并通过上下文不断修正任务条件。模型根据这些语言约束，在统一概率生成机制下给出响应。换言之，任务本身并非系统内部的固定对象，而是在语言交互过程中被逐步构建。这种机制使得任务定义权从软件设计者部分转移至用户语言表达之中，用户通过自然语言即可动态组合系统能力，从而实现高度灵活的问题求解过程。

随着 Prompt 机制的普及，人机关系的基本结构也发生了变化。传统软件依赖图形界面与功能按钮，用户通过结构化输入触发预定义流程，功能边界清晰且执行路径固定。在这种模式下，人机交互主要是操作行为：用户需要学习软件界面结构，并按照既定流程逐步完成任务。而生成式 AI 时代，自然语言逐渐成为底层交互协议。任务描述本身即为执行指令，用户无需理解系统内部逻辑，只需通过语言表达需求即可完成复杂操作。技术重心因此从“为任务构建模型”转向“为语言构建系统”。所有能力被映射为条件生成问题，通过同一模型结构完成，模型内部不再显式区分任务类型，而是通过上下文隐式切换行为模式。这种机制使得同一系统能够在不同场景下执行截然不同的任务，例如在同一次对话中完成信息查询、文本生成与逻辑分析等操作。能力不再分散于多个独立模块，而是整合于统一生成框架之中。

多轮对话机制进一步强化了这种转变。在传统软件中，大多数任务是一次性执行的：用户输入参数，系统返回结果，任务流程随之结束。而在对话系统中，问题解决过程呈现出动态展开的特征。模型能够在多轮交互中维持语境，理解前文信息，并根据新的输入不断修正假设与回答。例如用户可以先提出一个模糊问题，再通过连续对话逐步细化需求，模型在此过程中持续调整生成策略。这样的交互方式使得问题求解从单次调用的工具模式转变为持续协作的语义协商过程。人与模型之间不再只是“输入—输出”的关系，而更接近一种共同构建解决方案的互动关系。模型在对话中不仅提供信息，还能够帮助用户澄清问题、组织思路甚至提出新的解决路径，这种能力使语言模型逐渐表现出某种“认知工具”的特征。

从更宏观的系统层面看，ChatGPT 所代表的变化不仅是产品形态创新，更是一种软件组织方式的重构。传统软件系统通常围绕功能模块构建，其架构由多个独立组件组成，每个组件负责特定任务。而在大模型系统中，大量能力被整合进统一生成模型之中，系统的核心不再是功能模块，而是语言接口与上下文管理机制。模型通过统一的概率生成框架处理不同任务，软件系统则主要负责上下文维护、工具调用与外部资源整合。这种结构使语言成为新的计算接口，用户通过语言表达需求，系统通过生成模型理解并执行指令。由此，ChatGPT 所代表的并非单一产品创新，而是一种交互范式与系统组织方式的重构。它标志着人工智能从分散的功能集合走向统一生成平台，也预示着未来软件形态可能围绕语言接口重新组织其结构与逻辑。在这一新的技术框架中，语言不仅是沟通工具，也逐渐成为连接人与计算系统之间的核心协议。

### 2.1.4 从文本压缩到世界建模

生成式人工智能的深层革命性并不体现在训练目标的复杂性上，恰恰相反，其核心目标极为朴素——预测下一个词。无论是早期的神经语言模型还是当前的大规模 Transformer 系统，其训练目标本质上都可以被表述为对条件概率分布 $P(w_t|w_1,\ldots,w_{t-1})$ 的估计。这一目标看似只是对文本序列的统计建模，甚至可以被理解为一种规模化的“自动补全”任务。然而，当这一目标在数万亿词级别的语料与数百亿甚至数万亿参数规模的模型中被持续优化时，它所引发的结构性后果却远远超出了简单的文本预测。为了在统计意义上提高预测准确率，模型必须在极高维度的参数空间中寻找能够解释文本分布的稳定结构，而不是仅仅依赖表层词语的共现关系。换言之，语言模型所面对的问题并不仅是“如何补全一句话”，而是“如何在有限参数空间中压缩庞大而复杂的文本分布”。从信息论视角看，语言建模过程实际上是一种大规模概率压缩过程：模型通过学习数据分布的统计结构，将原本需要巨量存储的文本信息压缩为参数化表示。正是在这一压缩过程中，模型逐渐捕捉到语言背后更深层次的规律。

语言之所以可以被有效压缩，是因为其背后并非完全随机，而是由相对稳定的生成机制所驱动。自然语言不仅是符号序列，更是人类经验、社会实践与认知结构的外化表达。人类在描述世界时，会在语言中编码关于物理环境、社会关系、行为动机以及制度规则的各种知识。例如，当文本描述某个事件时，往往隐含时间顺序、因果关系与角色互动；当叙述社会行为时，则会反映文化规范与价值判断。这些结构性信息并不会总是以显式规则形式出现，但却在大规模语料中形成稳定统计模式。如果模型仅停留在局部词语共现层面，它在简单句子补全任务中或许仍能取得较高准确率，但在长文本生成、复杂情境推理或跨段一致性任务中便会迅速失效。因此，为了在复杂语境中维持语义连贯性，模型必须在参数空间中学习更抽象的结构表示，例如事件之间的因果关系、常识性约束以及社会行为模式。文本分布之所以可压缩，正是因为其背后存在相对稳定的世界结构；而模型若要实现高效压缩，实际上必须在内部逼近这一结构。某种意义上，语言模型在训练过程中所进行的并不仅是“压缩文本”，而是逐渐逼近文本所映射的生成机制，从而在统计层面形成一种隐式的世界模型。

当模型规模不断扩大、训练数据持续增长时，这种结构逼近能力会进一步增强。大规模语言模型通常在数千亿到数万亿词的语料上进行训练，这些语料覆盖百科知识、科学文献、新闻报道、技术文档以及社交媒体文本等多种来源。不同领域文本中所蕴含的知识结构在模型内部逐渐汇聚，并在多层神经网络表示中形成复杂的语义空间。在这一空间中，词语不再只是离散符号，而成为高维向量表示，语义关系则通过向量距离与方向体现。随着模型深度增加，不同层次逐渐捕捉到不同抽象程度的结构：低层表示往往对应词汇与语法关系，中层表示逐渐形成事件结构与语义角色，而高层则能够表达更复杂的概念关系与情境模式。在这种层级化表征之上，模型在行为层面开始表现出类似推理的能力，例如在多步问题中维持逻辑一致性、在复杂情境中保持角色关系稳定，或在长文本生成中维持主题连贯。这些能力并非通过显式规则编程获得，而是在压缩文本分布的过程中自然涌现。模型并不真正理解世界，也不具备意识，但其内部表示在统计意义上捕捉到了世界结构的某些稳定模式，因此能够在语言生成过程中复现这些模式。

正是在这种隐式结构建模能力之上，对齐训练（alignment training）才成为可能。原始语言模型的目标仅仅是最大化文本概率，其输出结果往往忠实反映训练语料中的统计特征，但未必符合人类社会的价值规范或交互需求。为了使模型行为更加可控，研究者引入了一系列对齐技术，例如基于人类反馈的强化学习（Reinforcement Learning from Human Feedback, RLHF）以及后续发展出的多种偏好优化方法。在这一过程中，人类标注者对模型输出进行评价，并将偏好信号反馈给模型，使其在生成文本时不仅追求概率最优，还逐渐符合人类期望的表达方式与价值取向。从结构角度看，这一过程实际上是在原有统计模型之上叠加一层社会约束，使模型输出逐渐适应人类交流环境。例如，模型会倾向于提供更有帮助性的回答，避免明显不当或有害的表达，并在不确定情境中表现出更加谨慎的语言策略。随着对齐训练不断迭代，模型逐渐从单纯的分布预测器转变为一种能够在社会语境中稳定互动的语言系统，其行为逻辑同时受到统计规律与人类反馈的塑形。

当语言模型在结构表示与社会对齐两个层面同时发展时，其角色也开始发生变化。最初的语言模型主要被视为自然语言处理任务的底层组件，例如用于机器翻译、文本分类或信息检索等应用。然而，在生成式人工智能框架下，大规模模型逐渐成为一种通用的认知接口。用户不再需要针对每个具体任务调用不同算法，而是通过自然语言描述问题，由模型在内部表示空间中完成信息检索、推理与生成过程。这种交互方式使语言模型从

单一工具演变为一种通用智能平台。它并不直接拥有世界经验，却通过压缩海量文本分布形成对世界结构的统计近似；它也并不具备人类式理解，却能够在语言层面模拟复杂认知行为。从这一角度看，生成式人工智能的核心突破并不只是模型规模扩大，而是信息组织方式的变化：文本压缩过程逐渐演化为世界结构建模过程，而语言模型也由此成为连接人类知识体系与计算系统的重要桥梁。在未来的发展中，这种基于语言的世界建模能力可能进一步与视觉、听觉以及行动数据结合，从而形成更加全面的多模态认知模型，为人工智能系统提供更接近现实世界的表征基础。

### 2.1.5 语言作为通用接口：智能形态的重组

当模型内部已经形成高维语义空间与隐式结构映射之后，自然语言开始承担新的角色——它不再只是信息表达的媒介，而逐渐演化为一种通用计算接口。在传统计算体系中，程序逻辑由开发者通过形式化编程语言精确描述，算法结构、执行路径与控制流程在系统设计阶段即被严格定义。软件系统的行为主要依赖显式规则控制，用户只能在开发者预先构建的菜单结构、功能模块与参数配置范围内进行操作。这种模式使计算系统具备高度确定性，但同时也限制了其适应复杂开放任务的能力。生成式人工智能的出现改变了这一基本结构。当模型通过大规模预训练在内部形成统一的语义表示空间之后，自然语言本身开始具备控制模型行为的能力。用户不再需要通过严格定义的程序接口调用系统功能，而是可以直接通过语言描述目标、设定约束或提供上下文信息，模型则在其内部表示空间中自动组织相关知识与推理路径。语言因此从传统的人机交流媒介，转变为能够驱动计算过程的通用接口层，使复杂任务能够以更加灵活的方式被表达与执行。

在这一新的交互框架中，Prompt 成为连接人类意图与模型行为的重要机制。所谓 Prompt Engineering，本质上是一种不同于传统编程方式的控制形式。与命令式编程需要逐步规定系统执行步骤不同，Prompt 更接近于声明式编程范式：用户并不明确指定每一个计算步骤，而是通过自然语言描述期望目标、提供必要条件或给出示例结构，从而引导模型在其内部语义空间中完成推理与生成过程。例如，在传统程序中，如果需要完成复杂数据分析，开发者必须逐步编写数据读取、特征提取、算法计算与结果输出等多个步骤；而在生成式模型环境中，用户可以通过一段自然语言描述任务需求，模型便能够在内部知识结构中自动组织相关信息并生成合理结果。Prompt 因此不仅是输入文本，更是一种任务描述语言。它可以定义角色、规定输出格式、设置逻辑约束或提供推理示例，使模型能够在条件约束下完成复杂问题求解。这种交互方式使自然语言具备类似编程接口的功能，也使普通用户能够以极低门槛参与复杂计算任务的构建过程。

语言接口的形成同时意味着计算控制方式的转变。在传统软件系统中，执行逻辑通常以明确的流程图或代码结构存在，程序运行路径在执行前已经确定。而在生成式模型框架下，许多计算步骤并未被显式编码，而是由模型在概率空间中动态生成。模型通过注意力机制与参数化知识结构，在给定上下文条件下自动选择最可能的语义路径并完成信息整合。这种机制使计算从“显式流程控制”逐渐转向“隐式语义调度”。用户提供的是问题描述与约束条件，而模型在内部空间中完成推理路径的选择与展开。换言之，生成式模型在某种意义上承担了隐式程序执行器的角色：Prompt 相当于程序声明，而模型内部的语义表示与参数结构则构成隐式执行环境。计算过程不再依赖固定算法流程，而是在大规模统计结构中动态展开。尽管这一过程本质上仍然是概率计算，但其表现形式已经接近于一种可通过语言进行操控的智能行为系统。

当自然语言成为统一接口之后，人工智能系统的能力组织方式也随之发生变化。在传统人工智能体系中，不同任务通常依赖不同模型结构，例如文本分类、机器翻译、问答系统或推荐系统往往分别由独立模型实现，各系统之间需要通过复杂接口进行协同。生成式模型的出现改变了这一模式。由于所有任务都可以被形式化为“在给定条件下生成最合适输出”的问题，不同能力形态逐渐被整合到统一生成框架之中。知识检索、文本生成、逻辑推理、代码生成以及数据解释等功能，都可以通过同一模型在不同上下文条件下实现。模型不再需要在不同任务之间切换结构，而是通过上下文信息调整其行为模式。这种机制使多种能力能够在同一语义空间中协同工作，从而显著降低系统复杂度。语言在这一过程中不仅是输入协议，同时也承担任务调度与结果表达的功能，类似于一种面向人类理解的“操作系统界面”。用户通过语言描述任务，模型通过语言返回结果，复杂能力在这一统一接口下被组织为连贯的智能行为。

这种接口层的变化最终带来了智能形态的整体重组。人工智能不再是由多个孤立任务模型组成的工具集合，

而是在统一生成框架下形成可扩展的能力平台。在这一结构中，知识、推理与生成不再分别属于不同系统模块，而是在共享参数空间与统一语义表示中协同运作。能力之间可以通过上下文自然组合，例如在一次交互中同时完成信息检索、逻辑分析与文本生成，而无需调用多个独立系统。语言成为贯穿整个系统的核心接口，使任务定义、策略控制与结果表达能够在同一媒介中完成。这种以语言为核心接口的架构，使人工智能逐渐从专用工具体系转向通用智能平台。在这一平台之上，新的应用不再需要重新构建复杂算法系统，而是可以通过语言描述快速组织已有能力。由此，人工智能的发展不再只是单一模型性能的提升，而是一种整体计算结构的转变。正是在这种结构性重组的基础上，跨行业的智能重构开始成为可能，而医疗等高度复杂领域也得以在统一语义框架下实现知识整合、推理协同与持续更新。

## 2.2 涌现能力：大模型为何与众不同？

然而，仅仅描述涌现现象本身并不足以解释其产生机制。为什么规模扩展会带来能力层级的跃迁，而不是简单的性能提升？要回答这一问题，需要将视角从外部行为转向模型内部表示结构的变化。随着参数规模与训练数据量的同步增长，模型内部的语义表示空间逐渐发生系统性重组：原本混叠的语义模式开始分化，抽象关系获得更加稳定的表达区域，不同知识结构之间的干扰逐渐减少。这种表示层面的结构演化，使模型能够在更大范围内维持信息一致性，并支持更长链条的逻辑依赖关系。因此，从表示学习的角度理解规模扩展如何改变语义空间结构，是理解大模型涌现能力的重要切入点。

### 2.2.1 规模扩展与表示结构的重组

涌现能力之所以会在规模扩展过程中出现，很大程度上源于模型内部表示结构的系统性变化。在传统机器学习模型中，参数规模的增加往往只意味着表达能力的渐进式提升，即模型能够在更复杂的函数空间中进行拟合。然而在大规模神经网络中，参数扩展不仅带来了容量提升，更改变了表示空间的组织方式。当模型参数数量与训练语料规模同步扩大时，内部语义空间逐渐形成更加细粒度且结构化的表示层级。不同语义概念、语法模式与知识片段在高维空间中形成相对稳定的分布区域，使模型能够在这些区域之间进行更加精确的映射与组合。这种结构化表示使模型不仅能够记忆更多知识，还能够在不同任务之间共享抽象结构，从而形成跨任务迁移能力。换言之，规模扩展使模型内部的语义空间逐渐从稀疏、混叠的表示形态转向更加清晰、可分离的结构布局。

随着表示空间维度与复杂度的提升，原本在小规模模型中相互干扰的语义模式开始获得更高程度的解耦。在较小模型中，不同语言结构或知识模式往往被压缩在有限参数空间内，彼此之间容易产生表示冲突，这种冲突会导致推理路径不稳定或生成过程出现漂移。当模型规模扩大后，更多参数为不同语义模式提供了独立表达区域，使模型能够在保持整体一致性的同时容纳多种复杂结构。这种现象可以从表示学习角度理解为语义空间分辨率的提升：当空间容量足够大时，模型能够为不同语义关系构建更加精细的几何结构，使抽象概念之间的距离与关系更加稳定。由此，模型不仅能够在局部上下文中完成预测，还能够在更长跨度的信息结构中维持一致性，这为多步推理与复杂任务执行提供了基础。

从更宏观的视角来看，这种表示结构的变化意味着模型内部逐渐形成层级化知识组织。低层表示往往编码词法模式与局部语法结构，中层表示捕捉句法依赖关系与语义角色，而更高层表示则能够表达跨句语境与抽象概念之间的关系。随着规模扩展，这些层级之间的分工逐渐稳定，使模型能够在统一结构中同时处理多种复杂语言现象。这种层级化表示并非通过人工设计规则实现，而是在大规模数据训练过程中自发形成。因此，规模扩展不仅改变模型的容量，更在内部构建出一种多层语义表示体系，使模型具备处理复杂结构关系的能力。涌现现象在某种意义上正是这种结构成熟度达到一定阈值后的外在表现。

### 2.2.2 上下文学习与推理能力的形成

除了表示结构的变化，大语言模型展现出的上下文学习能力同样体现了规模扩展所带来的机制性转变。在传统机器学习框架中，模型通常需要通过显式训练或参数更新来适应新的任务。当任务发生变化时，研究者往往需要重新收集数据并进行参数优化，使模型在新的任务分布上重新学习。然而，大语言模型在推理阶段却能

够直接利用提示信息调整行为。当用户在提示中提供少量示例或任务描述时，模型能够根据上下文条件迅速调整生成策略，而无需进行任何梯度更新。这种能力被称为“上下文学习”（in-context learning）。从表面上看，模型似乎在推理过程中完成了即时学习，但实际上其参数并未发生变化。模型并非真正重新训练，而是在已有表示空间中根据上下文条件动态组织信息路径，从而模拟出类似学习的行为。这种机制使语言模型能够在同一参数体系下处理大量不同任务，例如翻译、摘要、推理、代码生成或知识问答等，而无需为每一类任务单独训练模型。任务定义不再依赖固定的训练目标，而是通过提示中的语言结构动态构建。由此，学习过程部分从训练阶段转移到推理阶段，语言提示成为一种临时性的任务描述与行为控制机制。

上下文学习能力的出现表明，模型内部已经具备一种复杂的信息调度与条件控制机制。当提示中包含示例、规则或推理步骤时，模型能够在生成过程中主动提取这些结构模式，并将其映射到新的问题情境中。例如，在少样本学习场景中，提示中给出的若干示例实际上构成了一种临时任务模板，模型通过识别这些示例之间的结构关系来推断新的输入应当如何处理。这一过程并非简单的模仿复制，而是通过高维表示空间中的模式匹配与关系映射完成。当模型读取提示信息时，不同语义模式在内部表示空间中被激活，并形成一组条件约束，这些约束会影响后续 token 的生成概率分布。换言之，上下文在模型内部起到了一种“临时程序”的作用，它重新组织了模型已有知识，使其能够按照特定任务结构生成输出。这种机制在数学推理、逻辑分析以及代码生成任务中尤为明显。当提示中给出问题结构或示例推理步骤时，模型能够识别这些结构并延续相似的计算路径，从而在没有显式训练的情况下完成新的问题求解。

这种信息调度能力在链式思维提示（Chain-of-Thought Prompting）中表现得尤为突出。在传统生成模式下，模型往往直接输出最终答案，而在链式提示中，模型被引导先生成中间推理步骤，再逐步推导出结论。研究表明，这种显式推理路径能够显著提升复杂问题的解答质量，例如在数学推理、多步逻辑推断或复杂文本分析任务中，模型表现出明显更高的准确率。其原因在于，当模型被要求生成中间步骤时，推理过程被拆解为多个局部决策节点，每一步都在新的上下文条件下进行概率预测，从而降低单次预测错误导致整体失败的风险。从计算角度看，这意味着模型能够在高维表示空间中维持稳定的路径结构，使生成过程沿着特定逻辑轨迹推进，而不会在长序列生成中迅速偏离目标。与此同时，链式推理还能够强化模型内部的状态约束机制，使模型在多个步骤之间维持一致的语义目标。例如在数学问题求解过程中，变量关系与中间计算结果会在上下文中被持续引用，从而形成一种跨 token 的状态追踪能力。这种能力使模型能够处理更加复杂的任务，例如多步数学推理、程序生成以及复杂文本结构分析。

随着模型规模进一步扩大，这种推理能力逐渐从简单模式匹配演化为更复杂的结构推理。模型能够在较长上下文中维持一致性，跟踪变量关系，并在多轮推理过程中保持逻辑连贯。更重要的是，这种能力并不是通过显式符号推理模块实现的，而是在概率预测框架下通过表示结构与上下文调度机制自然形成。从理论上看，大语言模型仍然是在进行条件概率预测，即根据已有上下文预测下一个 token 的分布。然而，当表示空间的结构足够复杂且训练数据足够丰富时，概率预测过程可以在行为层面呈现出类似逻辑推理的特征。模型通过在高维语义空间中维持状态约束，使信息能够在长序列中持续传播，并在多个步骤之间保持一致性。由此产生的推理能力并不是独立模块，而是规模扩展、表示结构成熟以及上下文调度机制共同作用的结果。从更宏观的角度看，这种能力意味着模型不仅能够存储知识，还能够在生成过程中组织知识、调用知识并沿着抽象结构展开计算。尽管这种机制仍然属于统计学习框架，但其在外部行为上已经表现出超越传统神经网络的复杂性，也因此成为大模型区别于传统机器学习系统的重要特征之一。